

Manual Completo: Google Cloud Lab ARC110

Create a Streaming Data Lake on Cloud Storage

Este manual contiene las instrucciones detalladas para realizar el laboratorio de desafío ARC110 (Create a Streaming Data Lake on Cloud Storage). Se presentan dos alternativas para resolverlo:

- METODO A: Ejecucion rapida mediante la terminal de comandos (Cloud Shell).
- METODO B: Paso a paso visual utilizando la Consola Web de Google Cloud (Sin comandos).

El laboratorio tiene politicas restrictivas (constraints/gcp.resourceLocations) que impiden crear recursos en la region por defecto del laboratorio (us-east4). Por lo tanto, usaremos la region 'us-west1' para todos los recursos (Bucket, App Engine, Scheduler y Dataflow), la cual esta totalmente permitida por la politica.

METODO A: USANDO CLOUD SHELL (CON COMANDOS)

A.1. Configurar las Variables de Entorno

Abre Cloud Shell y ejecuta los siguientes comandos para definir las variables. Reemplaza los valores si tu laboratorio te asigna parametros especificos en las instrucciones:

```
export TOPIC_ID=mypubsub
export MESSAGE="Hello!"
export REGION=us-west1
export PROJECT_ID=$(gcloud config get-value project)
export BUCKET_NAME="${PROJECT_ID}-bucket"
```

A.2. Habilitar APIs de Google Cloud

Establece la region y activa las APIs de Dataflow y Cloud Scheduler. Es recomendable deshabilitar e iniciar nuevamente el servicio de Dataflow para asegurar su correcto estado de activacion.

```
gcloud config set compute/region $REGION

gcloud services disable dataflow.googleapis.com --force
gcloud services enable dataflow.googleapis.com cloudscheduler.googleapis.com
```

A.3. Crear Bucket y Topic de Pub/Sub

Crea el bucket de Storage (Data Lake) y el Topic de Pub/Sub:

```
gsutil mb -l $REGION gs://$BUCKET_NAME
gcloud pubsub topics create $TOPIC_ID
```

A.4. Crear App Engine y Cloud Scheduler Job en us-west1

Crea la aplicacion de App Engine en 'us-west1' (requerida por el Scheduler) y luego inicializa el scheduler job para publicar en el topic de Pub/Sub cada minuto:

```
gcloud app create --region=us-west1

gcloud scheduler jobs create pubsub publisher-job \
  --schedule="* * * * *" \
```

Manual Completo: Google Cloud Lab ARC110

Create a Streaming Data Lake on Cloud Storage

```
--topic=$TOPIC_ID \  
--message-body="$MESSAGE" \  
--location=us-west1
```

A.5. Forzar Ejecucion del Scheduler Job

Ejecuta manualmente el job en un bucle hasta que se ejecute exitosamente:

```
echo "Ejecutando Cloud Scheduler..."  
while true; do  
    if gcloud scheduler jobs run publisher-job --location="us-west1"; then  
        echo "Job ejecutado!"  
        break  
    fi  
    sleep 5  
done
```

A.6. Iniciar Job de Dataflow

Inicia el pipeline de streaming con la plantilla de Pub/Sub a Cloud Storage:

```
gcloud dataflow jobs run streaming-lake-job \  
    --gcs-location=gs://dataflow-templates/latest/Cloud_PubSub_to_GCS_Text \  
    --region=$REGION \  
    --worker-zone=us-west1-a \  
    --staging-location=gs://$BUCKET_NAME/tmp \  
    --parameters  
inputTopic=projects/$PROJECT_ID/topics/$TOPIC_ID,outputDirectory=gs://$BUCKET_NAME/temp/,outputFilenamePrefix=output
```

Manual Completo: Google Cloud Lab ARC110

Create a Streaming Data Lake on Cloud Storage

METODO B: USANDO LA INTERFAZ WEB (SIN COMANDOS)

B.1. Habilitar las APIs en la Consola Web

1. Ve al menu de navegacion (tres lineas horizontales arriba a la izquierda) y selecciona API y Servicios > Biblioteca.
2. Busca 'Dataflow API', haz clic sobre ella y presiona el boton Habilitar.
3. Regresa a la Biblioteca, busca 'Cloud Scheduler API' y haz clic en Habilitar.

B.2. Crear el Bucket de Storage (Data Lake)

1. En el menu de navegacion, selecciona Cloud Storage > Buckets.
2. Haz clic en Crear en la parte superior.
3. En Nombre de tu bucket, ingresa: '[ID_DE_TU_PROYECTO]-bucket' (ej: 'qwiklabs-gcp-03-be9cf5ea332d-bucket').
4. En Tipo de Ubicacion, selecciona Regional e ingresa 'us-west1'.
5. Deja todas las demas opciones por defecto y haz clic en el boton Crear. Confirma si aparece una advertencia de seguridad.

B.3. Crear el Topic de Pub/Sub

1. Navega a Pub/Sub > Topics en el menu lateral.
2. Haz clic en Crear Topic en la barra superior.
3. En ID del topic, ingresa: 'mypubsub'.
4. Asegurate de que la casilla 'Agregar una suscripcion predeterminada' este seleccionada y haz clic en Crear.

B.4. Crear la Aplicacion de App Engine

1. Ve a App Engine en el menu lateral de la consola.
2. Si se te solicita, haz clic en el boton Crear aplicacion.
3. En Region, selecciona 'us-west1' (Oregon) para cumplir con las politicas de la organizacion. IMPORTANTE: No elijas la region del lab si esta bloqueada.
4. Selecciona un lenguaje (por ejemplo, Python) en la configuracion inicial y finaliza la creacion.

B.5. Crear y Lanzar el Cloud Scheduler Job

1. Navega a Cloud Scheduler en el menu lateral.
2. Haz clic en Crear trabajo.
3. Llena la informacion basica:
 - Nombre: 'publisher-job'
 - Region: selecciona 'us-west1'
 - Frecuencia: escribe '* * * * *' (para que corra cada minuto)
 - Zona horaria: selecciona UTC
4. Configura el Destino:
 - Tipo de destino: selecciona 'Pub/Sub'
 - Tema (Topic): busca y selecciona el topic creado en el Paso B.3 (mypubsub)
 - Cuerpo del mensaje: escribe 'Hello!'
5. Haz clic en Crear.
6. Una vez creado, selecciona el trabajo en la lista y haz clic en el boton Forzar Ejecucion (Force Run). Esto enviara el primer mensaje al topic de inmediato.

Manual Completo: Google Cloud Lab ARC110

Create a Streaming Data Lake on Cloud Storage

B.6. Configurar y Desplegar el Job de Dataflow

1. Selecciona Dataflow > Jobs en el menu lateral de navegacion.
2. Haz clic en Crear Job a partir de plantilla (Create job from template) en la barra superior.
3. Rellena los campos con la siguiente informacion:
 - Nombre del job: 'streaming-lake-job'
 - Endpoint regional: selecciona 'us-west1'
 - Plantilla de Dataflow: selecciona la plantilla 'Pub/Sub Topic to Text Files on Cloud Storage' (dentro del grupo de Process Data Continuously / Streaming).
4. Configura los parametros requeridos en el formulario:
 - Input Pub/Sub topic: ingresa 'projects/[ID_DE_TU_PROYECTO]/topics/mypubsub'
 - Output directory in Cloud Storage: ingresa 'gs://[ID_DE_TU_PROYECTO]-bucket/temp/' (asegurate de terminar con barra '/')
 - Output filename prefix: ingresa 'output'
 - Staging/Temporary directory: ingresa 'gs://[ID_DE_TU_PROYECTO]-bucket/tmp/'
5. Despliega el job haciendo clic en Ejecutar Job (Run Job). El pipeline tardara 2-3 minutos en arrancar los recursos virtuales.